陈浚铭 (20337021)

实验理论：

算法原理与伪代码

卷积网络与普通神经网络的区别在，卷积神经网络包含了一个由卷积层(convolution layer)
和子采样曾（pooling layer)构成特征抽取器。在卷积网络的卷积层由一个神经元只与部分邻
层神经元连接。在 CNN 的卷积里面， 通常包含若干个特征图（feature map), 每个特征图有
一些排列的神经元组成，这里共享的权值就是卷积核。卷积核一般以随机小数矩阵的形式
初始化，在网络的训练过程中卷积核将学习得到合理的权值。共享权值（卷积核）带来的
直接好处是减少网络各层之间的连接，同时又降低了过拟合的风险。子采样也叫做池化（pooling），通常有均值子采样（mean pooling）和最大值子采样（max pooling）两种形
式。子采样可以看作一种特殊的卷积过程。卷积和子采样大大简化了模型复杂度，减少了
模型的参数。

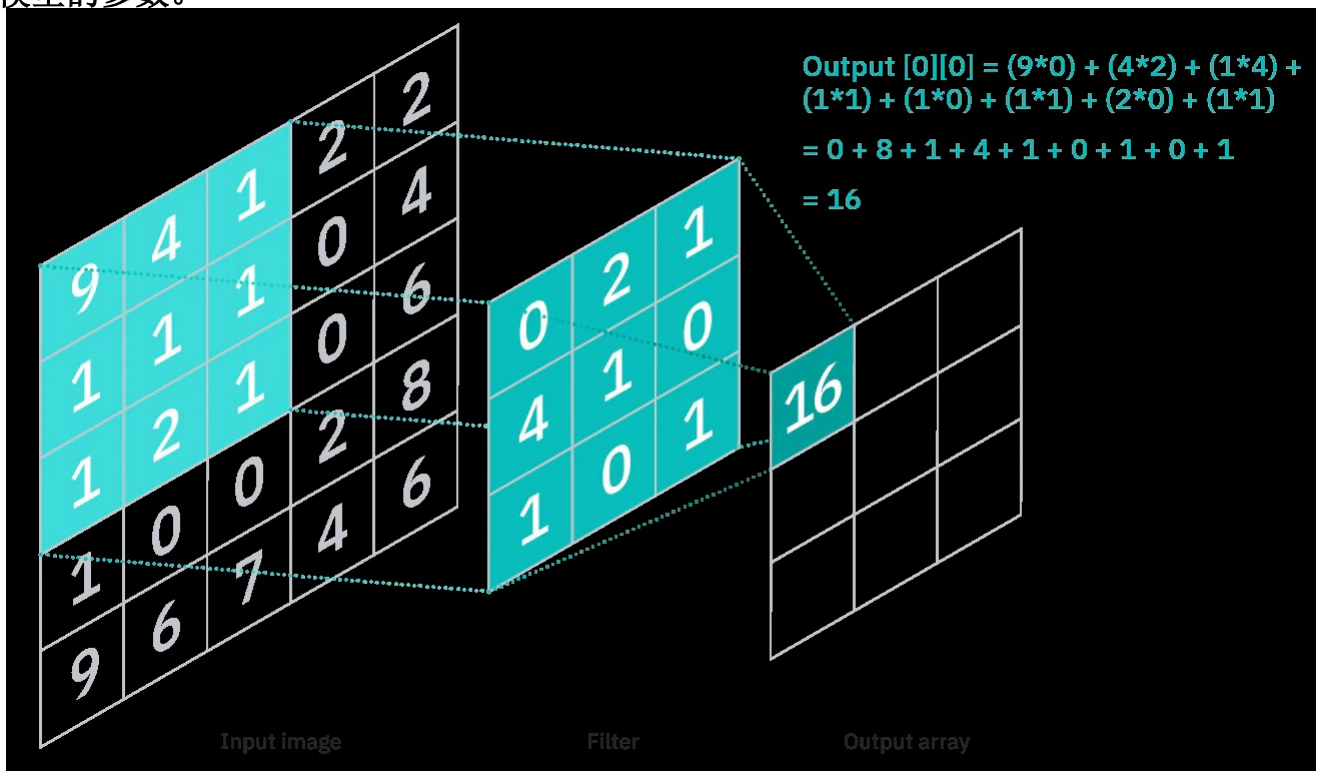

卷积层为 CNN 的核心组成部分，也是主要计算发生的地方。它需要一些重要的元素，例如
输入数据，过滤器和特征图。假设输入为一个 RGB 图像，则由一个个 pixel 组成的图像，这

意味着图像会是三维，代表图像的 R, G, B 值。我们也有个特征检测器，也叫做内核或者过
滤器，他会在图片上的感受野(receptive field)移动，检测是否存在该特征。这一个过程叫做
卷积。
特征检测器是一个权重的 2D 数组，代表图像的一部分，通常大小为 3x3。这也就是感受野
的大小。这样，过滤器就应用到该图像的部分，然后计算输入与过滤器之间的点积，然后
该值就成为输出层对应位置的值。之后，过滤器会根据一个 stride 移动，重复过程一直到
整个图像到扫了。最终的输出有一系列的点积就是特征图。
注意到在扫图像的过程中，filter 的值是维持不变的。这个特点叫做 parameter sharing。有
些参数，例如权重值，在训练过程中通过 gradient descent 或者 backpropagation 改变参数
值。但是这些超参量会影响到输出层的参数大小，而这些维度需要在训练神经网络前设定
包括：
过滤器的数量：这影响网络的深度
Stride: 过滤器在图像每次移动的长度
Zero padding: 通常被使用当过滤器不匹配输入图像的大小，这设定所有在图像以外过
滤器的值为 0，产生一个更大或者同大小的输出。有三种 padding:
valid padding: 也叫做 no padding。在这种情况，如果维度不匹配，最后的卷积就被略到。
Same padding: 这种 padding 保证输出层与输入层的大小相同。
Full padding: 这种 padding 增加输出图像的大小，通过在输入边界增加 0 值。
在每次卷积后， CNN 会应用 ReLU 转变到特征图，从而使得模型有非线性的元素。
Pooling layer 也叫做 Downsamping, 负责降低维度，减小输入图像的参数量。类似于卷积层，
pooling 层通过在整个图像扫一个过滤器，但不同是过滤器并没有任何的权重。反而，内核
应用一个聚合函数到感应野，最后输出到输出层。有两种主要的 pooling:
max pooling: 随着过滤器在输入图像移动，选择最大值到输出层
average pooling:随着过滤器在输入图像移动，选择平均值到输出层
Fully connected layer: 输出层的节点直接连接到前一层的节点，这一层通过在前一层所
采样的节点和它的不同过滤器进行分类，通常使用 softmax 函数来分类输入。

实验方法：

我们通过使用 pytorch 来实现我们的基于 cnn 的面型辨别模型。
我们的 cnn 结构大概为三层卷积层， 最后一层为全链接层。另外我们在每一个卷积层后面加上批标准化层，ReLU 层，和最后的最大池化层。最后的全链接层为一个线性层，标准化

层，ReLU 层， dropout 层和最后的线性层。当中这个 cnn 结构的批标准化层是一种为神经网络中的任何层提供 0 均值/单位方差输入的技术，能够改善人工神经网络的稳定性和性能。二 dropout 层以概率 p，随机将第一个先行曾的神经元的输出置为 0，作为第二个线性层的输出，这样可以防止模型的预测过于以来一些特定的神经元。我们使用的 optimizer 是 stochastic gradient descent(SGD)， 当中他的算法如下：

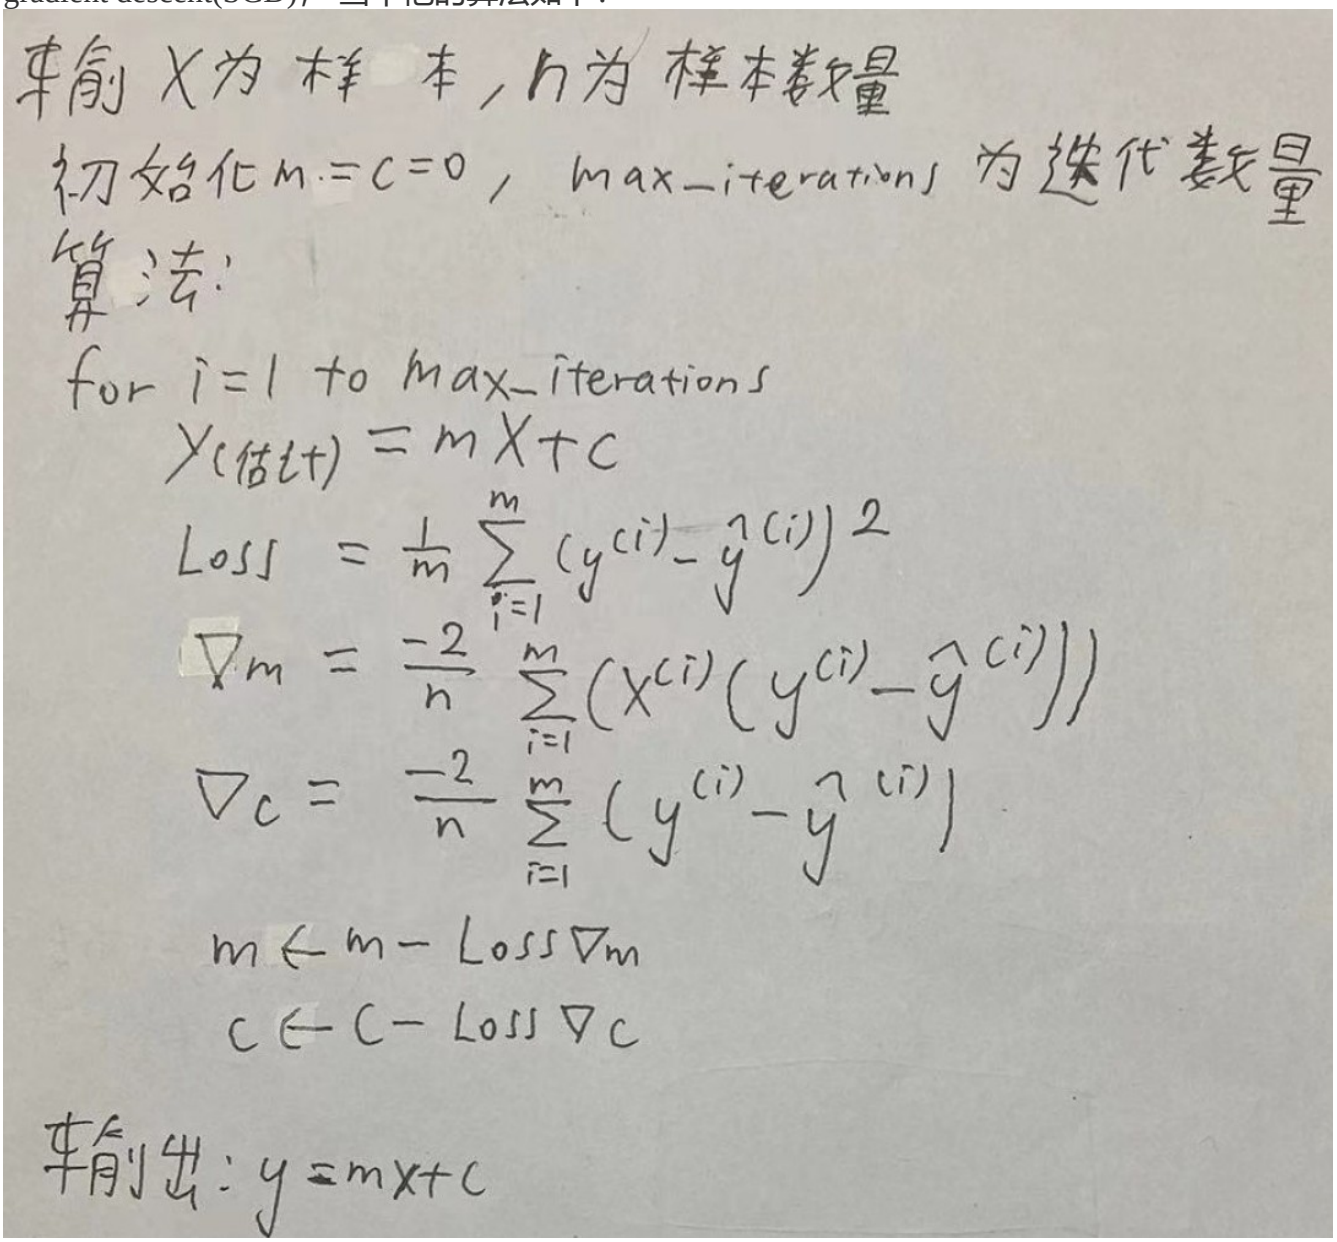

实验结果：
我们通过 cnn.py 迭代 50 次得到最好的训练模型，并最终在测试集运行结果，得到 46%的准确率：